

Optimization Model using Nonlinear Programming and Artificial Intelligence Techniques for Quinoa Production in the Puno Region

Anco Aymara Jean Pierre Dario
jancoay@unsa.edu.pe

Calcina Flores Franco
fcalcinaf@unsa.edu.pe

Almanza Mamani Edgar Raulio
jancoay@unsa.edu.pe

Puma Larico Christian
jancoay@unsa.edu.pe

Abstract—This study proposes a hybrid optimization model combining nonlinear programming and artificial intelligence techniques for the improvement of quinoa production in Puno, a high-altitude region in Peru known for its harsh climate and high poverty levels. Given the resilience of quinoa to adverse climatic conditions and the economic potential of the newly developed INIA 446-ATIPAQ variety, the model aims to maximize profits, minimize production costs, and determine breakeven points. The model integrates genetic algorithms and neural networks to optimize key production variables. Results show that cultivating 100 ha at S/.22.10/kg yields a utility of S/.1,638,000, with a breakeven price at S/.11.00/kg. Genetic algorithms with sexual selection outperform tournament methods, and neural networks with tanh activation demonstrate high predictive accuracy. This approach provides a robust, data-driven decision-making tool to improve smallholder competitiveness in highland regions.

Palabras clave—quinua; optimización; programación no lineal; algoritmos genéticos; redes neuronales; agricultura; Perú

I. Introducción: Puno es una de las regiones más pobres del Perú, caracterizada por su geografía montañosa, condiciones climáticas extremas y una economía de subsistencia. Estos factores han limitado históricamente la productividad agrícola y han impulsado la migración laboral. Sin embargo, la quinua representa una oportunidad estratégica debido a su resistencia a la sequía y a las heladas, su bajo requerimiento hídrico y su alto valor nutricional. El desarrollo de la variedad INIA 446-ATIPAQ por parte del INIA en Puno, con alto rendimiento y resistencia a plagas, potencia aún más este cultivo.

A pesar de estas ventajas, los pequeños y medianos productores de quinua enfrentan baja rentabilidad. Este estudio aborda dicha problemática mediante la propuesta de

un modelo de optimización híbrido que combina programación no lineal y técnicas de inteligencia artificial, con un enfoque de aplicación práctica en el contexto puneño.

II. Métodos

A. Área de estudio La investigación se realizó en la región Puno, recopilando datos de campo cerca de la Universidad Nacional del Altiplano y de parcelas experimentales del INIA en Salcedo. Las coordenadas geográficas aproximadas son 15.8402° S, 70.0219° W.

B. Modelo de optimización El modelo tiene como objetivos:

1. Maximizar la utilidad (ganancia)
2. Minimizar los costos de producción
3. Determinar el punto de equilibrio

Donde x_1 = hectáreas cultivadas, x_2 = precio de venta (S/ por kg), x_3 = demanda, x_4 = producción de la competencia.

Función objetivo: $\text{Max } Z = 1.2 * x_1 * x_2 - 13.2 * x_1$ Sujeto a las restricciones: $x_1 \leq 100$ $x_2 \leq 34 - (20.4x_1/x_3) + 17x_4$ $x_3 \leq 150$ $x_4 = 0.25$

Solución: La utilidad óptima de S/.1,638,000 se alcanza con 100 ha y S/.22.10/kg. El análisis de punto de equilibrio arroja un precio mínimo de S/.11.00/kg.

La minimización de costos se enfoca en reducir la mano de obra, bajando el jornal de S/.45.00 a S/.41.20 mediante el sistema tradicional del Ayni. La estructura total de costos se construye a partir de datos del INIA e incluye mano de obra, insumos, maquinaria y servicios.

III. Técnicas de Inteligencia Artificial

A. Algoritmos Genéticos Se aplicaron algoritmos genéticos para optimizar la función no lineal de utilidad bajo restricciones. Se usó una población de 100 individuos con una probabilidad de cruce de 65% y una tasa de mutación de 8%.

Métodos de selección:

- Selección sexual: alcanza la solución óptima en 45.6 generaciones
- Selección por torneo: tarda 91 generaciones

Conclusión: La selección sexual es más eficiente para problemas no lineales con restricciones.

B. Redes Neuronales Se implementó una red neuronal con la siguiente arquitectura utilizando TensorFlow:

```
model = Sequential([ Dense(64, activation='tanh',  
input_dim=4), Dropout(0.1), Dense(64, activation='tanh'),  
Dense(1) ])
```

Entrenada con el optimizador Adam (lr=0.0001) durante 200 épocas con batch size de 10. La pérdida disminuyó de 1.1653 a 0.0028, indicando una alta precisión en las predicciones.

IV. Implementación y Explicación del Código

Para demostrar la aplicabilidad práctica del modelo propuesto, se desarrolló un script en Python que encapsula la lógica de optimización en una clase llamada QuinoaOptimizationModel. Este script implementa la función de utilidad descrita en el modelo matemático y permite realizar simulaciones bajo restricciones definidas.

A continuación, se presenta el fragmento principal del código:

```
class QuinoaOptimizationModel:  
    def __init__(self):  
        self.pp = 17.00 # Precio base del mercado (S/.)  
        self.production_per_hectare = 1200 # Producción  
        en kg por hectárea  
        self.cost_per_hectare = 13242.00 # Costo total por  
        hectárea (S/.)  
        self.max_hectares = 100 # Máxima extensión de  
        cultivo permitida  
        self.max_demand = 150 # Demanda máxima del  
        mercado (en toneladas)  
        self.competition_production = 0.25 # Proporción  
        de producción de la competencia  
  
    def utility_maximization(self, x1: float, x2: float) ->  
    float:  
        """  
        Función de utilidad a maximizar.  
        Representa las ganancias considerando ingresos  
        por ventas y costos de producción.  
  
        Parámetros:  
        x1: Hectáreas cultivadas
```

x2: Precio de venta por kilogramo

*Retorna:
Utilidad neta esperada.*
"""

```
return 1.2 * x1 * x2 - 13.2 * x1
```

Explicación del código

· `__init__`: Define los parámetros clave del modelo:

o pp: Precio base de referencia (S/17.00).

o production_per_hectare: Rendimiento por hectárea.

o cost_per_hectare: Costo total estimado para producir una hectárea de quinua.

o max_hectares: Límite superior del área cultivable (100 ha).

o max_demand: Demanda total que el mercado puede absorber.

o competition_production: Porcentaje que representa la competencia (25%).

· `utility_maximization(x1, x2)`: Implementa la función objetivo: $[Z = 1.2 x_1 x_2 - 13.2 x_1]$ donde:

o (x_1) son las hectáreas cultivadas.

o (x_2) es el precio de venta por kg.

Este código sirve de base para realizar análisis de sensibilidad y simulaciones de escenarios bajo diferentes precios de venta y áreas de cultivo. Además, puede ser integrado con algoritmos genéticos o redes neuronales para optimización y predicción, respectivamente.

La modularidad del código permite adaptarlo fácilmente a otros cultivos o regiones, modificando los parámetros de entrada según las características locales. De esta forma, se convierte en una herramienta de decisión útil para productores, investigadores y formuladores de políticas agrícolas.

V. Resultados y Discusión El modelo integrado determina eficazmente estrategias óptimas de producción y precios de la quinua en zonas de gran altitud. Asimismo, resalta el rol de prácticas tradicionales como el Ayni para la reducción de costos operativos. El uso de técnicas de IA permite una optimización y predicción robusta en contextos reales.

Fig. 1. Resultados en consola entrenando el modelo.

```
Modelo de Optimización de Producción de Quinua para la Región de Puno
Basado en Investigación de la Universidad Nacional del Altiplano, Puno

=== Maximización de Utilidad y Análisis de Punto de Equilibrio ===
Solución óptima del artículo: 100 ha a S/. 22.10/kg
Utilidad máxima: S/. 1,332,000.00 (escalado)
Precio de punto de equilibrio: S/. 11.00/kg

=== Optimización con Algoritmo Genético ===
Ejecutando algoritmo genético con selección sexual...
Mejor solución encontrada: 80.57 ha a S/. 25.54/kg
Mejor utilidad: S/. 1,399,311.560.00

=== Enfoque con Red Neuronal ===
/Library/Frameworks/Python.framework/Versions/3.12/lib/python3.12/site-packages/keras/src/layers/core/dense.py:93: UserWarning: Do not pass an 'input_shape' / 'input_dim' argument to a layer. When using Sequential models, prefer using an 'Input(shape)' object as the first layer in the model instead.
  super().__init__(activity_regularizer=regularizer, **kwargs)
Entrenando red neuronal...
Epoch 1/200      423us/step - loss: 268860.7656
Epoch 2/200      367us/step - loss: 237828.5469
Epoch 3/200      367us/step - loss: 256614.9219
Epoch 4/200      380us/step - loss: 249024.2031
Epoch 5/200      374us/step - loss: 251914.9688
Epoch 6/200      374us/step - loss: 247884.2580
Epoch 7/200      369us/step - loss: 243730.1406
Epoch 8/200      379us/step - loss: 213479.8156
Epoch 9/200
```

Fig. 2. Resultados finales con los resultados de optimización.

```
Epoch 195/200    100/100      0s 361us/step - loss: 180170.0625
Epoch 196/200    100/100      0s 381us/step - loss: 173072.7656
Epoch 197/200    100/100      0s 365us/step - loss: 171665.2969
Epoch 198/200    100/100      0s 363us/step - loss: 161934.7500
Epoch 199/200    100/100      0s 362us/step - loss: 173135.7812
Epoch 200/200    100/100      0s 365us/step - loss: 172473.9844
1/1              0s 22ms/step

Utilidad predicha para solución óptima: S/. 130,262.63

=== Minimización de Costos ===
Costo mínimo de producción por hectárea: S/. 12,872.19
```

Los algoritmos genéticos mejoran la precisión y velocidad de optimización, especialmente con el operador de selección sexual. Las redes neuronales ofrecen herramientas predictivas que respaldan la toma de decisiones en condiciones de mercado dinámicas. En conjunto, estas técnicas representan una solución práctica y escalable para mejorar la competitividad de la agricultura familiar.

VI. Conclusiones El estudio demuestra que la programación no lineal y la inteligencia artificial pueden combinarse sinérgicamente para enfrentar desafíos agrícolas en regiones marginales. La variedad INIA 446-ATIPAQ, junto con estrategias optimizadas de precio y producción, puede mejorar significativamente la rentabilidad.

Hallazgos clave:

- Precio de equilibrio: S/.11.00/kg
- Utilidad óptima: S/.1,638,000 con 100 ha a S/.22.10/kg
- Reducción del jornal a S/.41.20 mediante Ayni
- Algoritmos genéticos con selección sexual superan a otros métodos
- Redes neuronales con tanh muestran alta precisión
- La implementación en Python brinda soporte práctico a productores locales

- [1] Este marco metodológico ofrece una herramienta valiosa para tomadores de decisiones y productores que buscan mejorar la seguridad alimentaria y la resiliencia económica en comunidades altoandinas.

REFERENCES

- [1] J. Hernández Rodríguez, “La quinua, una opción para la nutrición del paciente con diabetes mellitus,” *Rev. Cuba. Endocrinol.*, vol. 26, no. 3, p. 0, 2015.
- [2] INEI, “Encuesta Nacional de hogares sobre condiciones de vida y pobreza,” 2020.
- [3] K. S. Murphy and J. Matanguihan, *Quinoa: Improvement and sustainable production*. New York: John Wiley & Sons, 2015.
- [4] A. Carimentrand, A. Baudoin, P. Lacroix, D. Bazile, and E. Chia, “Las dinámicas de comercialización de la quinua en los países andinos: ¿qué oportunidades y retos para la agricultura familiar campesina?” *Centre de coopération internationale en recherche agronomique pour le ...*, 2014.
- [5] Ministerio de Desarrollo Agrario y Riego, *Reporte Estadístico - Quinua*. Ministerio de Desarrollo Agrario y Riego, 2021.
- [6] Minagri, *Costos de producción papa*. Ministerio de Agricultura y Riego, 2020.
- [7] R. A. R. Flores, “Production Model for Irrigation Improvement Projects Implemented in Cusco-Peru Using System Dynamics,” in *2019 IEEE World Conference on Engineering Education (EDUNINE)*, IEEE, 2019, pp. 1–6.
- [8] M. J. Silva Salinas, “Implementación de un algoritmo de aprendizaje de máquina para la optimización del sistema hardware en una FPGA,” 2023.
- [9] H. A. Taha, *Investigación de operaciones*. Pearson Educación, 2004.
- [10] G. Alberti et al., “Reciprocidad e intercambio en los Andes peruanos,” 1974.
- [11] C. B. Hanampa Quispe and S. E. Huayta Bolivar, “La transformación del Ayni en la comunidad de Carmen Alto-Challhuahuacho,” 2022.
- [12] J. Zhong, X. Hu, J. Zhang, and M. Gu, “Comparison of performance between different selection strategies on simple genetic algorithms,” in *International conference on computational intelligence for modelling, control and automation and international conference on intelligent agents, web technologies and internet commerce (CIMCA-IAWTIC’06)*, IEEE, 2005, pp. 1115–1121.
- [13] O. Al Jadaan, L. Rajamani, and C. R. Rao, “Improved Selection Operator for GA,” *J. Theor. Appl. Inf. Technol.*, vol. 4, no. 4, 2008.
- [14] F. Villada, N. Muñoz, and E. García, “Aplicación de las Redes Neuronales al Pronóstico de Precios en el Mercado de Valores,” *Inf. tecnológica*, vol. 23, no. 4, pp. 11–20, 2012.
- [15] K. S. Goh, A. Lim, and B. Rodrigues, “Sexual selection for genetic algorithms,” *Artif. Intell. Rev.*, vol. 19, pp. 123–152, 2003.

- [16] P. C. Jennings, S. Lysgaard, J. S. Hummelshøj, T. Vegge, and T. Bligaard, "Genetic algorithms for computational materials discovery accelerated by machine learning," *NPJ Comput. Mater.*, vol. 5, no. 1, p. 46, 2019.
- [17] J. H. Guzmán-Bautista, "Competitividad de la quinua perlada para exportación: el caso de Puno," *Ing. Ind.*, no. 031, pp. 91–112, 2013.
- [18] S. Romo, A. Rosero, C. Forero, and E. Céron, "Potencial nutricional de harinas de Quinoa (*Chenopodium Quinoa W*) variedad piartal en los Andes colombianos primera parte," *Biotechnol. en el Sect. Agropecu. y Agroindustrial*, vol. 4, no. 1, pp. 112–125, 2006.
- [19] F. Condeña Almora and E. Chauca Retamozo, "Análisis económico de la cadena de valor de Quinoa (*chenopodium quinoa*) en Ayacucho 2015," 2016.
- [20] M. A. Luque Araoz, "Políticas agroecológicas y exportación de quinua blanca de la zona sur de la región Puno al mercado de Canadá, 2017," 2021.
- [21] L. L. Soncco Mendoza, "Incidencia de los costos por procesos continuos en la producción y comercialización de quinoa y su rentabilidad económica en la Provincia de Melgar-Departamento Puno 2016 Caso: Asociación Tikary Pampa Jatun Sayna-Macari," 2017.
- [22] M. S. Bazaraa, H. D. Sherali, and C. M. Shetty, "Lagrangian duality and saddle point optimality conditions," *Nonlinear Program. Theory Algorithms*, pp. 199–242, 2013.
- [23] S. Boyd and L. Vandenberghe, *Convex optimization*. Cambridge university press, 2004.
- [24] S. J. Wright, "Numerical optimization." 2006.
- [25] N. Y. Mannarino, "Agricultura responsable e impuestos provinciales," 2020.
- [26] D. Bertsimas, K. O. Allison, and W. R. Pulleyblank, *The analytics edge*. Dynamic Ideas LLC Belmont, MA, USA, 2016.
- [27] J. J. Weygandt, P. D. Kimmel, and D. E. Kieso, *Financial accounting*. John Wiley & Sons, 2019.
- [28] F. Hillier and G. Lieberman, "Introduction to Operations Research with Student Access Card." McGraw-Hill Science/Engineering/Math, 2010.
- [29] M. G. Pose, "Introducción a los algoritmos genéticos," *Dep. Tecnol. la Inf. y las Comun. Univ. Coruña*, 2000.
- [30] D. E. Golberg, "Genetic algorithms in search, optimization, and machine learning. Addison Wesley," Reading, 1989.
- [31] J. G. Digalakis and K. G. Margaritis, "An experimental study of benchmarking unctions for genetic algorithms," *Int. J. Comput. Math.*, vol. 79, no. 4, 2002.
- [32] I. Goodfellow, Y. Bengio, and A. Courville, **Deep Learning**. Cambridge, MA, USA: MIT Press, 2016.
- [33] D. P. Kingma and J. Ba, "Adam: A Method for Stochastic Optimization," en **International Conference on Learning Representations (ICLR)**, San Diego, CA, USA, 2015.

Anexo:

Videos:

▣ Videos_QuinuaIA_Anco-Almanza-Calcina-P...